



Departamento de Ciência da Computação – UFSJ/DCOMP

PREVISÃO DO TOP 10 EM CORRIDAS DE FÓRMULA 1 A PARTIR DE CHECKPOINTS TEMPORAIS

Autores:

Arthur Henrique Moreira Santos

Gabriel da Silva Souza

Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG

2026

Sumário

1	Introdução	1
2	Trabalhos relacionados	1
3	Seleção e caracterização da base de dados	2
3.1	Origem e justificativa da escolha	2
3.2	Caracterização da coleção	2
4	Análise preliminar da qualidade dos dados	3
4.1	Cobertura temporal	3
4.2	Valores ausentes	3
4.3	Inconsistências e valores extremos	3
4.4	Considerações para o pré-processamento	4
5	Pergunta de Pesquisa e Objetivo	4
6	Metodologia	5
6.1	Seleção e recorte dos dados	5
6.2	Definição da unidade de análise e dos checkpoints	6
6.3	Pré-processamento e construção dos atributos	6
6.4	Definição da variável-alvo	8
6.5	Consolidação e validação da base analítica	8
6.6	Treinamento e avaliação dos classificadores	9
6.6.1	Algoritmos e conjuntos de atributos	9
6.6.2	Validação temporal e escolha das configurações	10
6.6.3	Tratamento dos dados e teste final	10
6.6.4	Métricas e registro dos experimentos	11
6.7	Reprodutibilidade e artefatos	11
7	Resultados Experimentais	12
7.1	Validação temporal	12
7.2	Teste final de 2020	12
7.3	Contribuição da posição de largada	14
7.4	Métricas complementares	14
7.5	Erros e variação entre corridas	16
7.6	Discussão e limitações	16
8	Conclusões	18

1 Introdução

A mineração de dados permite investigar padrões e relações em coleções de informações. Para que uma análise produza resultados interpretáveis, é necessário conhecer a origem dos dados, suas características e suas limitações antes de definir o problema de pesquisa e selecionar técnicas.

Os registros históricos da Fórmula 1 oferecem um contexto para esse tipo de estudo, pois reúnem informações sobre temporadas, corridas, pilotos, construtores e resultados [1]. Entretanto, a disponibilidade dos registros varia entre períodos, e mudanças nas regras da competição podem afetar comparações entre diferentes épocas.

Este trabalho investiga em qual momento de uma corrida é possível prever com maior confiabilidade quais pilotos terminarão entre os dez primeiros colocados. Para isso, utiliza dados históricos da Fórmula 1 entre 2017 e 2020, constrói observações nos checkpoints de 10%, 25%, 50% e 75% da prova e compara cinco algoritmos de classificação. O documento apresenta a seleção e a qualidade dos dados, o pré-processamento, o protocolo de validação temporal e os resultados obtidos no teste final de 2020.

2 Trabalhos relacionados

A revisão bibliográfica priorizou um estudo diretamente relacionado à previsão de resultados da Fórmula 1 e outro voltado à avaliação de classificadores binários.

Alahmadi et al. [2] aplicaram aprendizagem supervisionada à previsão de vencedores de corridas de Fórmula 1. Os autores utilizaram temporadas anteriores no treinamento e corridas posteriores no teste, evitando uma divisão aleatória que misturasse passado e futuro. Também identificaram a classificação e a posição de largada entre os atributos mais relevantes. Embora aquele estudo tenha como alvo o vencedor, sua separação temporal, a comparação entre classificadores e o uso de informações da posição de largada (grid) se aproximam das decisões adotadas neste trabalho.

No contexto da avaliação, Chicco e Jurman [3] demonstraram que o coeficiente de correlação de Matthews considera simultaneamente verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Essa propriedade fundamenta seu uso como medida complementar ao F1 e à acurácia, permitindo verificar se o desempenho não depende apenas de uma das classes.

Tashman [4] discutiu a importância de avaliações fora da amostra que respeitem a ordem das observações. Já Cawley e Talbot [5] mostrou que a seleção de modelos também pode sofrer sobreajuste quando avaliação e escolha não são adequadamente separadas. Esses cuidados fundamentam o uso de janelas temporais crescentes para escolher as configurações e de uma temporada final mantida fora dessa escolha.

Esses trabalhos fornecem referências para os principais componentes desta pesquisa: a previsão supervisionada de resultados da Fórmula 1, a separação temporal entre escolha e teste e a avaliação de uma tarefa de classificação binária por métricas complementares.

3 Seleção e caracterização da base de dados

3.1 Origem e justificativa da escolha

A base selecionada para o trabalho é a *Formula 1 World Championship (1950–2024)*, disponibilizada por Rao [1] na plataforma Kaggle. Segundo a página da coleção, os dados foram compilados a partir da Ergast Motor Racing Data e disponibilizados sob a licença CC0.

A escolha se justifica pela abrangência histórica, diversidade de informações e estrutura relacional. A coleção permite relacionar pilotos, construtores, corridas e temporadas, oferecendo possibilidades de investigação sobre desempenho esportivo, classificações e equilíbrio competitivo.

Além disso, a disponibilidade de trabalhos acadêmicos que utilizam a mesma coleção ou fontes relacionadas permite comparar abordagens e fundamentar as decisões metodológicas.

Neste trabalho, a coleção foi utilizada para construir uma tarefa de classificação binária voltada à previsão do top 10 final em diferentes momentos da corrida. O recorte temporal e os arquivos empregados nessa construção são apresentados na metodologia.

3.2 Caracterização da coleção

A coleção local reúne 701.433 registros distribuídos em 14 arquivos CSV, abrangendo temporadas de 1950 a 2024.

A Tabela 1 apresenta a composição dos arquivos utilizados.

Tabela 1: Composição da coleção local.

Arquivo	Registros
seasons.csv	75
circuits.csv	77
drivers.csv	861
constructors.csv	212
status.csv	139
races.csv	1.125
results.csv	26.759
qualifying.csv	10.494
sprint_results.csv	360
lap_times.csv	589.081
pit_stops.csv	11.371
driver_standings.csv	34.863
constructor_standings.csv	13.391
constructor_results.csv	12.625
Total	701.433

Fonte: levantamento dos arquivos locais.

Os arquivos possuem uma estrutura relacional, utilizando identificadores como `raceId`, `driverId` e `constructorId` para estabelecer relações entre as entidades.

Entretanto, apresentam diferentes granularidades. Enquanto `results` registra o resultado de um piloto em uma corrida, `lap_times` armazena individualmente suas voltas.

Dessa forma, a integração entre as tabelas exige atenção para evitar a multiplicação indevida de registros e possíveis distorções nas análises.

4 Análise preliminar da qualidade dos dados

A exploração inicial examinou a integridade estrutural, os valores ausentes, a cobertura temporal e possíveis inconsistências presentes na coleção.

4.1 Cobertura temporal

A disponibilidade dos dados não é uniforme entre as temporadas.

Os registros de classificação começam em 1994, os tempos por volta em 1996, as paradas nos boxes em 2011 e as corridas sprint em 2021.

Mesmo nesses intervalos, algumas temporadas apresentam cobertura incompleta.

Além disso, mudanças nos regulamentos, sistemas de pontuação e formatos das corridas limitam comparações diretas entre diferentes épocas.

4.2 Valores ausentes

A análise identificou padrões relevantes de ausência de informações.

Na tabela `results`, o campo `position` é nulo em 10.953 dos 26.759 registros (40,9%), frequentemente em situações como abandono, desclassificação ou não participação.

O campo `time` apresenta 71,3% de valores ausentes.

Na tabela `constructor_results`, o campo `status` está vazio em 12.608 dos 12.625 registros (99,9%).

Também foram identificadas ausências nos campos `q2` e `q3`, que podem estar relacionadas ao formato das sessões de classificação e à eliminação dos pilotos.

Esses resultados demonstram que os valores ausentes não devem ser tratados uniformemente ou substituídos automaticamente por zero.

4.3 Inconsistências e valores extremos

Foram identificados 1.638 registros com `grid=0`, valor que não representa uma posição convencional de largada.

Também foram encontrados 85 pares repetidos de corrida e piloto na tabela `results`. Esses registros correspondem a ocorrências históricas distintas e não devem ser removidos automaticamente como duplicatas.

Outras ocorrências incluem divergências entre `position` e `positionText` em dois resultados do Grande Prêmio da Austrália de 2005, além de tempos extremos em voltas e paradas.

Esses casos ainda precisam ser contextualizados antes de serem classificados como erros.

As verificações estruturais realizadas não identificaram problemas de integridade ou chaves estrangeiras inválidas.

4.4 Considerações para o pré-processamento

A avaliação preliminar indica que o tratamento da coleção deverá considerar a cobertura temporal, as diferenças de granularidade, os valores ausentes e as mudanças históricas das regras.

Com base nessa avaliação, os arquivos originais foram preservados e o pré-processamento foi executado somente sobre o recorte necessário à pergunta de pesquisa. Os critérios de seleção, limpeza e construção das variáveis são apresentados na metodologia, mantendo registradas as transformações realizadas.

5 Pergunta de Pesquisa e Objetivo

A disponibilidade de registros históricos de tempos de volta e posições dos pilotos permite investigar como a capacidade de prever o resultado de uma corrida evolui ao longo de sua realização. Entretanto, a quantidade de informações disponível varia conforme a prova avança, tornando necessário identificar em qual momento os dados observados permitem realizar previsões mais confiáveis.

Diante desse contexto, este trabalho busca responder à seguinte pergunta de pesquisa:

Em qual momento da corrida (10%, 25%, 50% ou 75% de sua distância) é possível prever com maior confiabilidade quais pilotos ativos terminarão entre os dez primeiros colocados?

O objetivo geral é investigar como o avanço da corrida influencia o desempenho de modelos de classificação na previsão dos pilotos que terminarão entre os dez primeiros colocados.

Neste trabalho, a confiabilidade preditiva é avaliada principalmente pelo F1 da classe positiva. Acurácia, precisão, revocação, MCC e PR-AUC são utilizadas como métricas complementares. Assim, a comparação identifica o checkpoint com melhor desempenho relativo, sem estabelecer um valor mínimo absoluto a partir do qual uma previsão possa ser considerada confiável.

Para isso, o problema é formulado como uma tarefa de classificação binária, na qual cada piloto observado em determinado momento da corrida recebe uma das seguintes classes:

- **Classe 1:** o piloto termina a corrida classificado entre os dez primeiros colocados;
- **Classe 0:** o piloto não termina a corrida classificado entre os dez primeiros colocados.

A investigação considera quatro momentos de observação, correspondentes a 10%, 25%, 50% e 75% da distância efetivamente disputada. Em cada momento, são utilizados atributos construídos a partir das informações disponíveis até aquele instante, incluindo posição atual, diferença de voltas, diferença temporal, ritmo relativo e posição de largada.

A comparação do desempenho preditivo entre os quatro momentos permitirá investigar a evolução da capacidade de previsão ao longo da corrida e identificar em qual checkpoint os modelos apresentam os resultados mais confiáveis, segundo as métricas de avaliação estabelecidas.

6 Metodologia

A metodologia adotada neste trabalho compreende a seleção dos dados, a definição da unidade de análise, o pré-processamento, a construção dos atributos e da variável-alvo e, posteriormente, o treinamento e a avaliação dos modelos de classificação.

O procedimento foi estruturado para investigar a evolução do desempenho preditivo ao longo da corrida, considerando quatro momentos de observação e utilizando exclusivamente atributos disponíveis até cada um deles.

6.1 Seleção e recorte dos dados

A pesquisa utiliza a coleção histórica Formula 1 World Championship (1950–2024), disponibilizada por Rao [1]. Embora a coleção original contenha 14 arquivos CSV, foram selecionados apenas quatro para a construção da base analítica:

- `racess.csv`: identificação das corridas, temporadas e datas;
- `results.csv`: participantes, posições de largada, resultados finais e situações de chegada;
- `lap_times.csv`: tempos de volta e posições registradas durante as corridas;
- `status.csv`: identificação das situações de chegada e abandono.

De `racess.csv` foram utilizados os identificadores, ano, etapa, nome e data da corrida. De `results.csv` foram lidos o identificador do resultado, a corrida, o piloto, o grid, a ordem final, o total de voltas e o status. De `lap_times.csv` foram empregados corrida, piloto, volta, posição e duração em milissegundos. `status.csv` forneceu a descrição associada a cada identificador de status. A classificação foi excluída porque o grid já representa a informação pré-corrida escolhida; as paradas nos boxes ficaram fora do escopo da pergunta; e os dados pessoais dos pilotos não foram necessários, pois sua identificação já estava presente nos resultados. Essa seleção reduziu o volume processado sem alterar os 14 arquivos originais.

Foi estabelecido um recorte temporal compreendendo as temporadas de 2017 – 2020, totalizando 79 corridas. A escolha busca reduzir a influência de diferenças regulamentares entre períodos históricos, uma vez que o intervalo começa após a mudança aerodinâmica de 2017 e termina antes da introdução das corridas sprint, em 2021, e das alterações regulamentares de 2022.

A temporada de 2020 apresenta particularidades decorrentes da pandemia de COVID-19, que deverão ser consideradas na interpretação dos resultados experimentais.

Os arquivos originais foram preservados, e o recorte foi realizado diretamente em memória, sem a necessidade de criação de um banco de dados intermediário.

Após a seleção, foram obtidos 1.580 registros de participação em corridas e 84.578 registros de tempos de volta, utilizados na construção da base analítica.

6.2 Definição da unidade de análise e dos checkpoints

A unidade de análise corresponde a um piloto considerado ativo em determinada corrida e em um dos momentos de observação definidos.

Foram estabelecidos quatro checkpoints, correspondentes a 10%, 25%, 50% e 75% da distância efetivamente disputada.

Para determinar a volta correspondente a cada checkpoint, utilizou-se a seguinte expressão:

$$V_c = \left\lceil \frac{V_t \cdot p}{100} \right\rceil \quad (1)$$

em que V_c representa a volta do checkpoint, V_t corresponde ao total de voltas efetivamente disputadas e p representa o percentual analisado.

O total de voltas foi obtido a partir do maior número de voltas registrado nos resultados da corrida e conferido com os registros de tempos de volta.

Para estabelecer um instante comum de observação, os tempos de volta foram acumulados individualmente para cada piloto. O instante do checkpoint foi definido como a primeira passagem registrada na volta correspondente, exigindo que essa passagem estivesse associada à primeira posição.

Para cada piloto, foi considerada somente a última passagem registrada até esse instante. Dessa forma, evita-se comparar diretamente informações de voltas registradas em momentos diferentes da corrida.

A seleção dos participantes também exigiu um tratamento para os abandonos, pois os arquivos utilizados não disponibilizam o instante exato de todas essas ocorrências.

Pilotos com situação de chegada classificada foram considerados ativos. Nos demais casos, a existência de uma passagem no instante do checkpoint ou posteriormente a ele foi utilizada como evidência retrospectiva de atividade. Na ausência dessa evidência, o piloto foi excluído daquele momento de observação.

As passagens posteriores foram empregadas exclusivamente na definição da população analisada, não sendo utilizadas na construção dos atributos preditivos.

Um piloto incluído em determinado checkpoint permanece na análise mesmo que abandone a corrida posteriormente.

Esse procedimento constitui uma reconstrução retrospectiva da população ativa. As passagens posteriores e a situação final não são utilizadas como atributos dos classificadores, mas auxiliam a decidir se o piloto deveria fazer parte de cada checkpoint. Portanto, uma aplicação em tempo real exigiria uma fonte que informasse diretamente o estado ativo dos pilotos no instante da previsão.

6.3 Pré-processamento e construção dos atributos

O pré-processamento foi realizado por meio de um script desenvolvido em Python, responsável pela leitura, integração, transformação e validação dos arquivos selecionados.

Inicialmente, foram verificadas a existência dos arquivos, a presença dos campos obrigatórios, os tipos de dados, a consistência das datas, a unicidade das chaves e as relações entre corridas, participantes, situações de chegada e tempos de volta.

As verificações de unicidade consideraram `raceId` nas corridas, `resultId` e o par corrida–piloto nos resultados, o trio corrida–piloto–volta nos tempos de volta e `statusId` nos status. Também foi conferida a continuidade das voltas de cada piloto. Uma falha nessas condições interrompe o processo antes da publicação da base, cuja gravação é atômica para evitar a substituição da saída válida por um arquivo incompleto.

Também foi verificada a continuidade dos registros de voltas de cada piloto. Caso alguma validação obrigatória apresentasse falha, o processamento seria interrompido antes da geração da base final.

Após essas verificações, foram construídos seis atributos candidatos para a etapa de modelagem:

- **Posição atual:** classificação do piloto reconstruída no instante do checkpoint, considerando o número de voltas concluídas e o tempo acumulado da última passagem registrada;
- **Voltas de diferença para o líder:** diferença entre a volta correspondente ao checkpoint e o número de voltas concluídas pelo piloto;
- **Diferença temporal:** diferença entre o tempo acumulado do piloto e o tempo da primeira passagem registrada na mesma volta concluída;
- **Ritmo relativo:** razão entre a mediana dos tempos de volta do piloto e a mediana dos tempos de volta do líder, considerando o mesmo intervalo de voltas;
- **Posição de largada:** posição convencional ocupada pelo piloto no grid de largada;
- **Indicador de largada não convencional:** variável binária que identifica os registros cuja posição de largada é igual a zero.

A posição atual foi reconstruída pela quantidade de voltas concluídas, utilizando o tempo acumulado como critério de ordenação entre pilotos na mesma volta. O identificador do piloto foi empregado apenas como critério técnico de desempate.

O ritmo relativo foi calculado pela razão:

$$R_i = \frac{\tilde{T}_i}{\tilde{T}_L} \quad (2)$$

em que $\tilde{T}_i$ representa a mediana dos tempos de volta do piloto e $\tilde{T}_L$ representa a mediana dos tempos de volta do líder, calculadas sobre o mesmo intervalo observado.

A primeira volta foi desconsiderada nesse cálculo por incluir a largada, que não representa uma volta convencional de corrida.

Valores próximos de 1 indicam ritmos medianos semelhantes. Valores superiores a 1 representam um tempo mediano maior para o piloto, enquanto valores inferiores a 1 representam um tempo mediano menor.

Os valores ausentes foram tratados de acordo com seu significado. Especificamente, quando a posição de largada original era igual a zero, o atributo de posição convencional foi mantido como ausente e o indicador de largada não convencional recebeu valor 1.

Não foram realizadas imputações globais nem normalizações nesta etapa. Caso sejam necessárias, essas transformações deverão ser ajustadas exclusivamente com os dados de treinamento, evitando a utilização de informações dos conjuntos de validação e teste.

Também não foram criados registros sintéticos ou estimadas posições intermediárias entre passagens.

6.4 Definição da variável-alvo

A variável-alvo foi denominada `top_10_final` e representa a classificação final do piloto como pertencente ou não ao grupo dos dez primeiros colocados.

Seu valor foi definido como:

$$y_i = \begin{cases} 1, & \text{se o piloto termina classificado no top 10;} \\ 0, & \text{caso contrário.} \end{cases} \quad (3)$$

Para receber o valor 1, o piloto deve apresentar posição final de ordem menor ou igual a dez e possuir situação de chegada classificada, identificada como `Finished` ou `+N Lap(s)`.

Pilotos que abandonaram posteriormente ao checkpoint permanecem na base, mas recebem o valor 0.

A posição final exata não é utilizada como variável a ser prevista, pois o objetivo é identificar apenas a permanência no grupo dos dez primeiros colocados.

A variável-alvo é construída a partir dos resultados finais da corrida, enquanto os atributos preditivos são limitados às informações disponíveis até o checkpoint correspondente.

6.5 Consolidação e validação da base analítica

Ao término do pré-processamento, foi gerado o arquivo `base_checkpoints.csv`, contendo 5.747 observações e 11 colunas, referentes a 79 corridas e 34 pilotos distintos.

A distribuição temporal compreende 1.399 observações em 20 corridas de 2017, 1.509 em 21 corridas de 2018, 1.609 em 21 corridas de 2019 e 1.230 em 17 corridas de 2020. Foram identificadas 68 linhas sem posição convencional de largada; nelas, `grid_position` permaneceu ausente e `non_standard_grid_start` recebeu o valor 1.

As 11 colunas estão distribuídas em quatro campos de identificação e controle, seis atributos candidatos à modelagem e uma variável-alvo.

Os campos de identificação e controle permitem reconhecer a corrida, a temporada, o piloto e o checkpoint, mas não devem ser utilizados automaticamente como atributos numéricos preditivos.

A quantidade de observações por checkpoint é apresentada na Tabela 2.

A redução no número de observações ao longo da corrida está relacionada principalmente à exclusão de pilotos sem evidência de atividade nos checkpoints posteriores. A coluna “sem volta” registra participações sem passagem disponível, enquanto “sem atividade” reúne pilotos cuja última evidência de atividade ocorreu antes do instante analisado.

Tabela 2: Distribuição das observações por checkpoint.

Checkpoint	Observações	Sem volta	Sem atividade
10%	1.504	47	29
25%	1.461	47	72
50%	1.420	47	113
75%	1.362	47	171
Total	5.747	188	385

Fonte: elaboração própria.

Antes da geração do arquivo final, foram realizadas verificações de unicidade, consistência dos atributos, validade da variável-alvo e continuidade das posições reconstruídas.

Foram confirmadas as 316 combinações esperadas entre as 79 corridas e os quatro checkpoints. Cada combinação apresenta exatamente dez pilotos classificados no top 10 atual e dez registros positivos na variável-alvo.

Não foram identificadas chaves duplicadas na base gerada.

O processamento também produz registros de auditoria, contendo as validações realizadas, os motivos de exclusão de observações e uma assinatura SHA-256 do arquivo final, permitindo verificar sua integridade e reprodutibilidade.

6.6 Treinamento e avaliação dos classificadores

Concluída a preparação dos dados, realizou-se uma etapa experimental de classificação supervisionada para prever se cada piloto considerado ativo em um checkpoint terminaria entre os dez primeiros colocados. Foram avaliados cinco algoritmos, em quatro momentos da corrida (10%, 25%, 50% e 75%), sob um protocolo comum de treinamento e avaliação. Os checkpoints foram tratados separadamente, de modo que cada ajuste utilizasse observações correspondentes a um único momento da prova.

6.6.1 Algoritmos e conjuntos de atributos

A implementação foi desenvolvida em Python, com o auxílio da biblioteca *scikit-learn*. Foram utilizados Regressão Logística, Árvore de Decisão, Random Forest, Gradient Boosting e Máquina de Vetores de Suporte (SVM). A seleção reuniu um modelo linear, um classificador baseado em regras, dois métodos de combinação de árvores e um classificador baseado em margens, permitindo comparar abordagens com diferentes formas de aprendizagem.

Redes neurais não foram incluídas porque a base é tabular, possui somente seis atributos candidatos e um número efetivo de 79 corridas. Nesse contexto, os cinco métodos escolhidos permitem comparar relações lineares, regras, conjuntos de árvores e separação por margens sem ampliar desnecessariamente a complexidade do experimento.

Cada algoritmo foi avaliado com dois conjuntos de atributos. O primeiro, denominado *informações da corrida*, incluiu posição atual, voltas de atraso em relação ao líder do checkpoint, diferença temporal reconstruída e ritmo relativo. O segundo, denominado *informações da corrida e grid*, acrescentou aos quatro atributos anteriores a posição de largada e o indicador de largada não conven-

cional. A comparação entre esses conjuntos constituiu uma análise complementar da contribuição das informações anteriores à largada, sem alterar a pergunta de pesquisa principal.

As colunas `race_id`, `year`, `driver_id` e `checkpoint_percent` foram utilizadas apenas para identificação, separação temporal e organização dos experimentos; não foram fornecidas aos classificadores. A variável `top_10_final` foi empregada exclusivamente como alvo. Como referência sem aprendizado, também foi avaliada a regra que prevê top 10 para pilotos com `current_position` menor ou igual a dez e prevê a classe negativa para os demais.

6.6.2 Validação temporal e escolha das configurações

Para respeitar a ordem cronológica e evitar que registros relacionados à mesma corrida fossem distribuídos entre treinamento e avaliação, adotou-se validação temporal com janelas crescentes. Foram executadas duas divisões: treinamento em 2017 e validação em 2018; em seguida, treinamento em 2017–2018 e validação em 2019. Os modelos foram ajustados novamente do início em cada divisão. Não foi empregada separação aleatória dos registros.

A busca de hiperparâmetros contemplou 29 configurações: três de Regressão Logística (C igual a 0,1; 1 ou 10); seis de Árvore de Decisão (profundidade máxima de 3, 5 ou 8 e mínimo de 5 ou 15 amostras por folha); seis de Random Forest (300 árvores, profundidade máxima de 5, 10 ou ilimitada e mínimo de 1 ou 5 amostras por folha); oito de Gradient Boosting (50 ou 100 árvores, taxa de aprendizado de 0,05 ou 0,1 e profundidade de 1 ou 2); e seis de SVM (*kernel* linear ou RBF e C igual a 0,1; 1 ou 10). No caso do *kernel* RBF, utilizou-se `gamma=scale`.

Cada uma das 29 configurações foi avaliada nos quatro checkpoints, nos dois conjuntos de atributos e nas duas divisões temporais, resultando em 464 ajustes. Para cada combinação de algoritmo, checkpoint e conjunto de atributos, selecionou-se a configuração com maior F1 médio nas validações de 2018 e 2019. Em caso de empate, priorizou-se a menor diferença absoluta entre os dois valores de F1; persistindo o empate, manteve-se a primeira configuração da ordem previamente estabelecida na grade. Assim, foram selecionadas 40 configurações, correspondentes a cinco algoritmos, quatro checkpoints e dois conjuntos de atributos.

6.6.3 Tratamento dos dados e teste final

As transformações dependentes dos dados foram incorporadas aos *pipelines* e ajustadas exclusivamente com as observações de treinamento de cada divisão. Nos cenários que incluíram o grid, as posições de largada ausentes foram preenchidas com a mediana das posições disponíveis no respectivo conjunto de treinamento, arredondada para o inteiro mais próximo, com metades arredondadas para cima. O indicador de largada não convencional foi preservado. Regressão Logística e SVM receberam padronização por `StandardScaler`; Árvore de Decisão, Random Forest e Gradient Boosting utilizaram os atributos em sua escala original. Não foram gerados exemplos sintéticos nem aplicados balanceamento ou pesos de classe. Nas operações aleatórias, foi utilizada a semente 42.

Como parâmetros fixos, a Regressão Logística utilizou o solucionador `liblinear`, penalização L2 e até 1.000 iterações. A Random Forest utilizou 300 árvores, seleção de atributos pela raiz quadrada

do total e paralelização nos núcleos disponíveis. Os algoritmos com operações aleatórias receberam `random_state=42`; no SVM com núcleo RBF, foi mantido `gamma=scale`.

Após a seleção dos hiperparâmetros, cada uma das 40 configurações foi treinada novamente com as temporadas de 2017 – 2019 e avaliada na temporada de 2020, mantida separada durante toda a etapa de seleção. A referência sem aprendizado foi avaliada nos mesmos checkpoints e períodos. O ano de 2020 foi utilizado apenas como teste final; as configurações estabelecidas anteriormente não foram modificadas com base em seus resultados.

6.6.4 Métricas e registro dos experimentos

A métrica principal de seleção e comparação foi o F1 da classe positiva (`top_10_final = 1`), que combina precisão e revocação. Também foram calculadas acurácia, precisão, revocação, MCC, PR-AUC e matrizes de confusão, separadamente para cada algoritmo, conjunto de atributos e checkpoint. O MCC resume os quatro componentes da matriz de confusão e varia de -1 a 1 , sendo incluído como medida complementar por considerar acertos e erros das duas classes [3].

A PR-AUC foi calculada como *Average Precision* a partir do escore contínuo `top10_score`. Nos classificadores que oferecem `predict_proba`, esse escore corresponde à estimativa associada à classe positiva; no SVM, corresponde ao valor produzido pela função de decisão e não deve ser interpretado diretamente como probabilidade. MCC e PR-AUC não foram utilizados para trocar as configurações escolhidas pelo F1 nas validações. As métricas da referência simples foram registradas nas mesmas condições, possibilitando a comparação com a manutenção do top 10 observado durante a corrida.

A classificação foi realizada individualmente para cada piloto, por meio da classe retornada pelo método `predict`. Portanto, os modelos não foram obrigados a produzir exatamente dez previsões positivas por corrida: o problema avaliado foi a classificação binária de cada participante, e não a construção de uma lista ordenada com dez nomes. Os resultados e as previsões individuais foram preservados em arquivos CSV, acompanhados das configurações selecionadas, matrizes de confusão e registros de execução, de modo a permitir a conferência e a reprodução das análises.

Na avaliação final, os modelos produziram entre 8 e 15 previsões positivas por corrida e cenário. Dos 680 grupos formados por corrida e cenário de modelo, 351 apresentaram exatamente dez previsões positivas. Essa variação é compatível com a formulação binária adotada; obrigar a seleção dos dez maiores escores constituiria outro protocolo experimental.

A interpretação dos resultados deve considerar que as duas validações abrangem apenas as temporadas de 2018 e 2019, que os pilotos de uma mesma corrida não constituem observações independentes e que o calendário de 2020 foi atípico. Essas limitações serão consideradas na discussão dos resultados experimentais, apresentada na seção seguinte.

6.7 Reprodutibilidade e artefatos

O fluxo foi executado em contêiner com Python 3.12.3, NumPy 2.3.3, *pandas* 2.3.3 e *scikit-learn* 1.9.1. A base analítica utilizada nos resultados possui a assinatura SHA-256 `e454e98335870181fa8e87f2e9edad74c3555c41dad6ae7846996909dfdc0c9`. Os arquivos finais registram essa

assinatura, a versão do protocolo e a semente, permitindo relacionar as métricas à entrada utilizada.

O fluxo pode ser reproduzido a partir da raiz do projeto com os seguintes comandos:

- `docker compose run -rm tp1 verificar`: confere o ambiente e a base sem ajustar classificadores;
- `docker compose run -rm tp1 preprocessar -overwrite`: recria a base analítica;
- `docker compose run -rm tp1 validar`: executa a validação temporal;
- `docker compose run -rm tp1 testar`: executa o teste final;
- `docker compose run -rm tp1 analisar`: produz as tabelas e visualizações da análise.

As saídas preservadas incluem 44 linhas de resultados da validação, 44 linhas da avaliação final, 176 células de matrizes de confusão e 13.530 previsões individuais. Estas últimas mantêm corrida, piloto, checkpoint, algoritmo, atributos, configuração, classe real, classe prevista, escore contínuo e indicação de acerto, permitindo recalcular métricas e realizar análises por corrida sem repetir o treinamento. Os modelos ajustados não foram serializados, pois o objetivo foi documentar o experimento, e não implantar um serviço de predição.

7 Resultados Experimentais

7.1 Validação temporal

Nas validações de 2018 e 2019, o maior F1 médio de cada algoritmo ocorreu no checkpoint de 75%. Os valores ficaram entre 0,890 e 0,895, sendo o maior deles obtido pelo Gradient Boosting com os atributos da corrida. Esses resultados foram utilizados somente para escolher os hiperparâmetros de cada combinação de algoritmo, checkpoint e conjunto de atributos, sem consultar a temporada de 2020.

A Figura 1 apresenta o comportamento do F1 médio nos quatro checkpoints e mantém separados os dois conjuntos de atributos.

7.2 Teste final de 2020

No teste final, o melhor F1 observado aumentou ao longo dos quatro checkpoints. O maior valor foi 0,913, alcançado pelo SVM com informações da corrida e do grid no checkpoint de 75%. Nesse cenário, a acurácia foi 0,898, a precisão 0,898 e a revocação 0,929. O MCC foi 0,789 e a PR-AUC foi 0,944.

A evolução do F1 de todos os algoritmos no teste final é apresentada na Figura 2.

A referência simples, que mantém no top 10 final os pilotos presentes no top 10 do checkpoint, alcançou F1 de 0,912 aos 75%. Portanto, embora esse momento tenha apresentado o maior desempenho absoluto, o SVM superou a referência em aproximadamente 0,002. O maior ganho sobre a referência ocorreu no checkpoint de 50%, com diferença de 0,034. Esse resultado indica que a informação




Figura 1: F1 médio nas validações de 2018 e 2019 por checkpoint e conjunto de atributos. Fonte: elaboração própria.




Figura 2: F1 dos classificadores no teste final de 2020. Fonte: elaboração própria.

acumulada até 75% torna a previsão mais precisa, mas também torna a própria posição atual uma referência muito forte.

A Figura 3 destaca o maior F1 observado em cada checkpoint e sua diferença para a referência simples.




Figura 3: Maior F1 observado em 2020 comparado à referência simples. Fonte: elaboração própria.

7.3 Contribuição da posição de largada

Nas validações, o conjunto com grid superou o conjunto formado somente pelos dados da corrida em 14 das 20 comparações, enquanto os dados da corrida foram melhores em quatro e houve dois empates. Em dois dos quatro casos favoráveis ao conjunto sem grid, a diferença foi inferior a 0,001.

No teste de 2020, a inclusão do grid aumentou o F1 em 15 das 20 comparações, manteve o resultado em duas e o reduziu em três. O ganho médio foi 0,008. Assim, a posição de largada apresentou contribuição preditiva, mas sua influência foi pequena em parte dos cenários e não substituiu as informações observadas durante a corrida.

A Figura 4 mostra a diferença de F1 produzida pela inclusão do grid em cada algoritmo e checkpoint.

7.4 Métricas complementares

O crescimento observado pelo F1 também aparece no MCC e na PR-AUC. No cenário de maior F1 do SVM aos 75%, o MCC foi 0,789 e a PR-AUC foi 0,944. As Figuras 5 e 6 apresentam essas métricas em todos os checkpoints, algoritmos e conjuntos de atributos. Elas são utilizadas como evidências complementares e não alteram a seleção realizada pelo F1.




Figura 4: Efeito da inclusão da posição de largada sobre o F1 no teste de 2020. Fonte: elaboração própria.




Figura 5: MCC por checkpoint no teste final de 2020. Fonte: elaboração própria.




Figura 6: PR-AUC por checkpoint no teste final de 2020. Fonte: elaboração própria.

7.5 Erros e variação entre corridas

As matrizes de confusão da Figura 7 permitem observar separadamente os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos dos cenários de maior F1 em cada checkpoint. Essa separação complementa o valor agregado do F1 e mostra quais tipos de erro permaneceram em cada momento da corrida.

As métricas consolidadas agrupam todos os pilotos avaliados em 2020. Para verificar a variação entre provas, a Figura 8 apresenta a distribuição do F1 calculado separadamente por corrida. A dispersão observada mostra que o desempenho não foi uniforme entre os eventos, embora os resultados no checkpoint de 75% tenham sido mais concentrados em valores elevados.

7.6 Discussão e limitações

A combinação de algoritmo e atributos com maior F1 na validação coincidiu com a de maior F1 observada em 2020 em apenas um dos quatro checkpoints. Essa variação reforça a importância de manter a temporada final separada e de não reajustar os modelos a partir de seus resultados.

A interpretação também deve considerar que o teste final contém somente as 17 corridas de 2020, temporada com calendário atípico em razão da pandemia de COVID-19. Além disso, pilotos da mesma corrida compartilham condições de prova e não constituem observações totalmente independentes. Não foram calculados intervalos de confiança, e a identificação dos pilotos ativos foi reconstruída retrospectivamente devido à ausência do instante exato de todos os abandonos.

A posição e a diferença temporal também foram reconstruídas pelas últimas passagens completas disponíveis. A soma dos tempos de volta não reproduz todos os detalhes do relógio oficial em provas interrompidas, e `gap_to_lap_leader_ms` não corresponde necessariamente ao intervalo exibido pela cronometragem ao vivo. Em corridas encurtadas, até a distância efetivamente disputada, usada para localizar os checkpoints, pode ser conhecida apenas ao final da prova. Essas escolhas tornam o estudo reproduzível com os CSVs disponíveis, mas limitam sua aplicação direta em tempo real.

O ritmo relativo calculado aos 10% utiliza poucas voltas e pode ser mais sensível a neutralizações ou




Figura 7: Matrizes de confusão dos cenários de maior F1 no teste de 2020. Fonte: elaboração própria.




Figura 8: Distribuição do F1 entre as corridas de 2020. Fonte: elaboração própria.

voltas atípicas. A coleção também não registra diretamente clima, compostos de pneus, acionamentos de Safety Car ou Virtual Safety Car e zonas de DRS. Como essas condições podem afetar o ritmo e as posições, os resultados não devem atribuir toda variação observada apenas aos pilotos, carros ou algoritmos.

8 Conclusões

Este trabalho investigou como a capacidade de prever o top 10 final evolui nos checkpoints de 10%, 25%, 50% e 75% de uma corrida. Entre os momentos avaliados, o melhor desempenho ocorreu aos 75%: o SVM treinado com informações da corrida e do grid alcançou F1 de 0,913 no teste final de 2020. O crescimento do F1 ao longo dos checkpoints também foi acompanhado pelas métricas complementares. Assim, em termos relativos, o checkpoint de 75% apresentou a maior confiabilidade preditiva no recorte analisado.

Esse resultado, contudo, deve ser interpretado em conjunto com a referência simples. Aos 75%, prever que os pilotos presentes no top 10 permaneceriam nesse grupo produziu F1 de 0,912, menos de 0,002 abaixo do melhor classificador. O maior ganho sobre a referência ocorreu aos 50%, com diferença de 0,034. Desse modo, o checkpoint mais tardio oferece o maior desempenho absoluto, enquanto o checkpoint intermediário evidencia melhor a contribuição adicional dos modelos em relação à posição observada durante a prova.

A inclusão da posição de largada elevou o F1 em 15 das 20 comparações no teste final, com ganho médio de 0,008. Entretanto, os modelos que utilizaram somente os dados da corrida foram melhores em três comparações e apresentaram o mesmo resultado em outras duas. Nas validações, os dados da corrida sem o grid também foram superiores em quatro das 20 comparações, embora em dois desses casos a diferença tenha sido inferior a 0,001. Portanto, o grid apresentou informação preditiva na maioria dos cenários, mas seu efeito não foi uniforme e não substituiu os atributos construídos a partir do andamento da corrida. Em conjunto, os resultados mostram que o desempenho preditivo aumentou com o avanço da prova e que diferenças pequenas entre modelos exigem interpretação cautelosa.

As conclusões se restringem às temporadas de 2017 – 2020 e a um teste final formado pelas 17 corridas de 2020, cujo calendário foi atípico. Também devem ser consideradas a reconstrução retrospectiva dos pilotos ativos, a dependência entre observações da mesma corrida e a ausência de intervalos de confiança. Trabalhos futuros podem ampliar o número de temporadas avaliadas, utilizar uma fonte que informe em tempo real a situação dos pilotos e estimar a incerteza das diferenças observadas entre os classificadores.

Referências

- [1] Rohan Rao. *Formula 1 World Championship (1950–2024)*. Kaggle. URL: <https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020> (acesso em 18/09/2026).
- [2] Lusan Alahmadi et al. “Predicting Formula One Race Outcomes Using Supervised Machine Learning”. Em: *2026 IEEE 15th International Conference on Communication Systems and Network Technologies (CSNT)*. IEEE, 2026, pp. 403–408. DOI: [10.1109/CSNT69054.2026.11502479](https://doi.org/10.1109/CSNT69054.2026.11502479). URL: <https://doi.org/10.1109/CSNT69054.2026.11502479>.
- [3] Davide Chicco e Giuseppe Jurman. “The Advantages of the Matthews Correlation Coefficient (MCC) over F1 Score and Accuracy in Binary Classification Evaluation”. Em: *BMC Genomics* 21.1 (2020), p. 6. DOI: [10.1186/s12864-019-6413-7](https://doi.org/10.1186/s12864-019-6413-7). URL: <https://doi.org/10.1186/s12864-019-6413-7>.
- [4] Leonard J. Tashman. “Out-of-sample Tests of Forecasting Accuracy: An Analysis and Review”. Em: *International Journal of Forecasting* 16.4 (2000), pp. 437–450. DOI: [10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0). URL: [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0).
- [5] Gavin C. Cawley e Nicola L. C. Talbot. “On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation”. Em: *Journal of Machine Learning Research* 11 (2010), pp. 2079–2107. URL: <https://www.jmlr.org/papers/v11/cawley10a.html>.